Questions d'entretien

Enterprise RAG & Agentic AI Platform

Parcours de l'entretien



OBJECTIF DU GUIDE

Vous aider à expliquer le projet avec un discours structuré, technique mais accessible, et à répondre honnêtement aux questions de profondeur.

Document de préparation | Version du 20 août 2026

Projet : BilalBouizdouzene/Enterprise-RAG-Agentic-AI-Platform

PHRASE À RETENIR

J'ai construit une plateforme de connaissance d'entreprise local-first qui ingère des documents, combine recherche lexicale et vectorielle, cite ses sources et route les demandes vers des outils contrôlés.

Comment utiliser ce guide

Ne mémorisez pas chaque phrase. Retenez la logique : problème, choix technique, preuve, limite et prochaine amélioration.

Situation	Durée	Structure recommandée
Présentation rapide	30 secondes	Problème + solution + valeur
Présentation technique	90 secondes	Architecture + pipeline RAG + sécurité
Discussion approfondie	5 à 10 minutes	Choix, compromis, métriques et limites
Question comportementale	1 à 2 minutes	Contexte + action + résultat + apprentissage

Résumé du projet en 10 lignes

1. Le produit répond aux questions internes à partir d'une base documentaire contrôlée.
2. L'utilisateur échange avec une interface web servie par FastAPI.
3. Les documents sont chargés, découpés en chunks et indexés.
4. La recherche combine BM25 et similarité dense.
5. La fusion RRF améliore la complémentarité des résultats.
6. Les réponses incluent des citations de sources pour être vérifiables.
7. Un routeur agentique sélectionne la recherche documentaire ou un outil contrôlé.
8. Redis et un worker séparent les uploads de l'indexation asynchrone.
9. Qdrant, PostgreSQL et MinIO apportent la persistance dans Docker.
10. L'API key, les tests et les métriques forment la base de la mise en production.

RÈGLE D'OR

Ne prétendez pas avoir mesuré un score que vous n'avez pas réellement calculé. Dites plutôt quelles métriques vous avez définies et comment vous les mesureriez sur un jeu de questions annoté.

1. Questions d'ouverture et de cadrage

Ces questions arrivent souvent dans les premières minutes. Elles évaluent votre capacité à expliquer la valeur avant les détails.

QUESTION 01

Présentez ce projet en deux minutes.

RÉPONSE MODÈLE

J'ai développé une plateforme de knowledge management basée sur le RAG et l'agentic AI. Elle permet de charger des documents d'entreprise, de les indexer, puis de répondre avec des extraits cités. Le pipeline combine recherche BM25, recherche dense, fusion des résultats et reranking optionnel. Une API FastAPI expose le système à une interface web, tandis que Docker orchestre Qdrant, Redis, PostgreSQL, MinIO et le worker d'indexation. Mon objectif était d'avoir une base local-first, testable et évolutive, avec des garde-fous de sécurité et une réponse vérifiable.

RELANCE POSSIBLE

Quel choix technique avez-vous le plus défendu ?

ÉLÉMENT À MONTRER

Page de couverture, schéma d'architecture et README.

QUESTION 02

Quel problème métier le projet résout-il ?

RÉPONSE MODÈLE

Dans une entreprise, l'information est dispersée dans des PDF, procédures et politiques. Une recherche par mots-clés seule rate les formulations différentes, alors qu'un chatbot sans sources peut halluciner. La plateforme rapproche les deux besoins : retrouver le bon passage et rendre la réponse traçable pour que l'utilisateur puisse la vérifier.

RELANCE POSSIBLE

Qui sont les utilisateurs cibles ?

ÉLÉMENT À MONTRER

Exemples de questions et citations S1, S2, S3 dans l'interface.

QUESTION 03

Pourquoi avoir choisi le RAG plutôt qu'un fine-tuning ?

RÉPONSE MODÈLE

Le RAG est adapté quand les données changent et doivent rester privées. On peut mettre à jour l'index sans réentraîner le modèle, citer les passages utilisés et limiter la réponse au corpus autorisé. Le fine-tuning pourrait améliorer un style ou une tâche stable, mais il ne remplace pas une source documentaire à jour.

RELANCE POSSIBLE

Dans quel cas le fine-tuning serait-il pertinent ?

ÉLÉMENT À MONTRER

Section RAG du dossier technique.

QUESTION 04

Quelle valeur apporte l'aspect agentique ?

RÉPONSE MODÈLE

Le RAG répond aux questions documentaires. L'agent apporte une couche de décision : il peut choisir entre la recherche de documents et un outil spécialisé, par exemple une requête SQL en lecture seule. L'intérêt n'est pas de donner une autonomie illimitée au modèle, mais d'orchestrer des actions explicites avec des entrées et sorties contrôlées.

RELANCE POSSIBLE

Comment évitez-vous qu'un agent exécute n'importe quoi ?

ÉLÉMENT À MONTRER

Routeur et liste des tools autorisés dans le code.

QUESTION 05

Quel était votre rôle exact dans le projet ?

RÉPONSE MODÈLE

J'ai pris en charge la conception de l'architecture, le pipeline d'ingestion et de retrieval, l'API, l'interface web, l'authentification locale, Docker, les tests et la documentation. Je peux distinguer ce qui est déjà implémenté de ce qui reste une étape de production, comme le SSO, la gestion fine des rôles ou un déploiement cloud managé.

RELANCE POSSIBLE

Quel élément avez-vous livré en premier ?

ÉLÉMENT À MONTRER

Historique Git, structure du dépôt et tests.

2. Architecture et flux de données

L'objectif est de montrer que vous comprenez le système de bout en bout et pas seulement le modèle de langage.

QUESTION 06

Décrivez l'architecture technique.

RÉPONSE MODÈLE

Le navigateur parle à FastAPI, qui gère l'authentification, les uploads, les questions et les métriques. Le pipeline RAG récupère les chunks depuis la couche de retrieval et le vector store. Redis met les indexations en file, le worker les traite, Qdrant stocke les vecteurs, PostgreSQL les données structurées et MinIO les objets documentaires. En développement, le système peut fonctionner avec des composants mémoire ou SQLite ; Docker fournit le profil persistant.

RELANCE POSSIBLE

Quel composant remplaceriez-vous en premier en cloud ?

ÉLÉMENT À MONTRER

Schéma Runtime architecture du dossier technique.

QUESTION 07

Pourquoi FastAPI et une interface web au lieu de Streamlit ?

RÉPONSE MODÈLE

Streamlit est très pratique pour un prototype de démonstration, mais une interface web séparée donne davantage de contrôle sur la navigation, l'authentification, le design, les uploads et l'intégration future avec un SSO. FastAPI fournit aussi une API claire pour connecter d'autres clients, automatisations ou applications internes.

RELANCE POSSIBLE

Quels compromis avez-vous acceptés ?

ÉLÉMENT À MONTRER

Dossier frontend_web et routes FastAPI.

QUESTION 08

Expliquez le chemin d'un document depuis l'upload.

RÉPONSE MODÈLE

L'API valide la requête et le fichier, puis conserve l'original dans le stockage objet lorsque ce profil est actif. Une tâche d'indexation est placée dans Redis. Le worker récupère le fichier, extrait le texte, le découpe en chunks avec leurs métadonnées, calcule les représentations, écrit les points dans Qdrant et met à jour l'état du job. L'interface interroge ensuite le statut pour afficher la progression.

RELANCE POSSIBLE

Que faites-vous si le worker tombe ?

ÉLÉMENT À MONTRER

Logs du worker, file Redis et statut d'indexation.

QUESTION 09

Quel est le rôle de Docker Compose ?

RÉPONSE MODÈLE

Compose permet de reproduire localement un environnement composé de plusieurs services : API, worker, PostgreSQL, Redis, Qdrant et MinIO. Les volumes rendent les données persistantes et le réseau interne évite d'exposer chaque service à l'extérieur. C'est utile pour le développement et pour une première démonstration proche de la production, même si un orchestrateur est préférable à plus grande échelle.

RELANCE POSSIBLE

Quelle différence avec Kubernetes ?

ÉLÉMENT À MONTRER

docker-compose.yml et profils de service.

QUESTION 10

Comment concevriez-vous la séparation entre tenants ?

RÉPONSE MODÈLE

Je ne me contenterais pas d'un filtre côté interface. Chaque document et chaque chunk devraient porter un tenant_id, et ce filtre serait imposé côté API et retrieval. En production, je compléterais par des rôles, des politiques d'accès, des tests d'isolation et éventuellement des collections ou namespaces séparés selon le niveau de risque.

RELANCE POSSIBLE

Comment testeriez-vous une fuite de données ?

ÉLÉMENT À MONTRER

Métadonnées des chunks et contrôles d'autorisation.

3. Retrieval, RAG et qualité des réponses

Ici, l'entretien vérifie votre compréhension de la recherche d'information, pas uniquement votre connaissance des LLM.

QUESTION 11

Décrivez votre pipeline RAG étape par étape.

RÉPONSE MODÈLE

Je normalise la question, je lance des recherches lexicales et denses, puis je fusionne les candidats avec Reciprocal Rank Fusion. Un reranker peut réordonner les passages les plus prometteurs. Les chunks retenus sont envoyés au prompt avec leurs métadonnées. Enfin, la réponse est validée pour conserver les citations et signaler lorsque le contexte ne suffit pas.

RELANCE POSSIBLE

Où placeriez-vous un cache ?

ÉLÉMENT À MONTRER

Schéma du pipeline et modules retrieval.

QUESTION 12

Pourquoi combiner BM25 et recherche dense ?

RÉPONSE MODÈLE

BM25 est très bon pour les termes exacts, les noms de procédures, les codes et les acronymes. La recherche dense capte mieux la similarité sémantique et les reformulations. Leur combinaison réduit le risque de rater une information importante à cause d'un seul mode de recherche.

RELANCE POSSIBLE

Que se passe-t-il pour un acronyme rare ?

ÉLÉMENT À MONTRER

Modules sparse.py et dense.py.

QUESTION 13

Qu'est-ce que RRF et pourquoi l'utiliser ?

RÉPONSE MODÈLE

RRF attribue un score aux résultats selon leur rang dans chaque liste, puis additionne ces contributions. Il évite de devoir calibrer directement des scores issus de modèles différents. C'est un compromis simple et robuste pour fusionner BM25 et dense avant un reranking éventuel.

RELANCE POSSIBLE

Quelle alternative testeriez-vous ?

ÉLÉMENT À MONTRER

Module fusion.py et tests de retrieval.

QUESTION 14

Comment choisissez-vous la taille des chunks ?

RÉPONSE MODÈLE

Je cherche un compromis entre contexte suffisant et précision de récupération. Des chunks trop courts perdent la relation entre les phrases ; trop longs, ils ajoutent du bruit et dépassent le budget de contexte. Je mesurerais cette décision sur un jeu de questions avec plusieurs tailles, un overlap contrôlé et les métriques hit@k et faithfulness.

RELANCE POSSIBLE

Les titres et pages sont-ils conservés ?

ÉLÉMENT À MONTRER

Métadonnées source, page et identifiant de chunk.

QUESTION 15

Comment garantissez-vous les citations ?

RÉPONSE MODÈLE

Chaque chunk conservé doit garder une référence stable : source, page et identifiant. Le prompt demande au générateur de répondre à partir du contexte, puis la réponse est vérifiée pour conserver les références attendues. Une citation n'est utile que si elle permet de retrouver le passage original, donc je testerais aussi ses liens avec des documents réels.

RELANCE POSSIBLE

Que faites-vous si aucune source n'est assez proche ?

ÉLÉMENT À MONTRER

Exemples [S1], [S2], [S3] dans les réponses.

QUESTION 16

Comment réduisez-vous les hallucinations ?

RÉPONSE MODÈLE

Je limite le contexte aux passages récupérés, j'impose une consigne de refus ou d'incertitude lorsque les preuves sont insuffisantes et j'affiche les sources. Je complète cela par une évaluation de faithfulness, des tests adversariaux et un contrôle humain pour les cas sensibles. Le système ne doit pas transformer une absence de preuve en certitude.

RELANCE POSSIBLE

Une citation garantit-elle la vérité ?

ÉLÉMENT À MONTRER

Section limites et évaluation.

QUESTION 17

Quand utiliser un reranker ?

RÉPONSE MODÈLE

Le reranker est utile lorsque la première récupération produit beaucoup de candidats et que l'ordre des résultats est imparfait. Je l'appliquerais sur un top-k limité, car il coûte plus cher que la recherche initiale. Il doit être évalué par rapport au gain de recall ou de précision et à son impact sur la latence.

RELANCE POSSIBLE

Comment éviter une latence excessive ?

ÉLÉMENT À MONTRER

Configuration RERANKER_MODEL et métriques de latence.

4. Agentic AI, outils et garde-fous

Le mot agentic doit être expliqué concrètement : décisions, outils, état et limites.

QUESTION 18

Qu'est-ce qui est réellement agentique dans votre application ?

RÉPONSE MODÈLE

Le système ne fait pas seulement un appel fixe à un LLM. Un routeur interprète l'intention et sélectionne un chemin, comme la recherche documentaire ou un outil SQL read-only. Chaque outil possède un contrat et produit un résultat que le pipeline peut intégrer. L'agenticité est donc l'orchestration contrôlée, pas une liberté d'action générale.

RELANCE POSSIBLE

Quelle action n'autoriseriez-vous jamais par défaut ?

ÉLÉMENT À MONTRER

Router, tools et contrôles d'accès.

QUESTION 19

Comment contrôlez-vous les requêtes SQL ?

RÉPONSE MODÈLE

Je limite l'outil à la lecture seule, je valide la structure attendue, je bloque les instructions d'écriture et je limite les tables ou colonnes accessibles. En production, j'utiliserais un compte DB sans droits d'écriture, un timeout, une limite de lignes et des logs d'audit. Le modèle ne doit jamais obtenir les privilèges de l'application.

RELANCE POSSIBLE

Comment traitez-vous une demande ambiguë ?

ÉLÉMENT À MONTRER

Outil SQL et configuration PostgreSQL/SQLite.

QUESTION 20

Comment gérez-vous le prompt injection dans un document ?

RÉPONSE MODÈLE

Je considère le contenu récupéré comme une donnée, pas comme une instruction système. Les documents sont séparés des consignes dans le prompt, les outils ont une allow-list et les entrées sont journalisées. Pour un niveau supérieur, j'ajouterais un classifieur ou une étape de détection, des tests d'injection et une validation humaine pour les actions à risque.

RELANCE POSSIBLE

Le prompt seul est-il une défense suffisante ?

ÉLÉMENT À MONTRER

Section sécurité et roadmap.

QUESTION 21

Quand l'agent doit-il refuser de répondre ?

RÉPONSE MODÈLE

Lorsqu'il n'a pas de preuve suffisante, lorsque la demande sort du périmètre, ou lorsqu'elle demande une action non autorisée. Le refus doit être utile : expliquer la limite, citer ce qui a été trouvé et proposer une prochaine étape, par exemple contacter le service compétent.

RELANCE POSSIBLE

Comment distinguer incertitude et absence de résultat ?

ÉLÉMENT À MONTRER

Réponses avec sources et messages d'erreur.

QUESTION 22

Comment observer le comportement d'un agent ?

RÉPONSE MODÈLE

Je loguerais l'intention, l'outil choisi, les paramètres non sensibles, les résultats, la latence et la décision finale. Les secrets et données personnelles doivent être masqués. Des traces corrélées par request_id rendent le diagnostic possible sans enregistrer aveuglément tout le contenu utilisateur.

RELANCE POSSIBLE

Quelles métriques suivez-vous ?

ÉLÉMENT À MONTRER

Observabilité, audit et tests.

5. Uploads, indexation et diagnostic

Ces questions s'appuient sur les problèmes rencontrés pendant la démonstration et montrent votre capacité à diagnostiquer.

QUESTION 23

Que signifie le message 0/1 document indexed ?

RÉPONSE MODÈLE

Cela signifie que le job d'indexation a échoué pour le document. Dans le cas rencontré, l'API a rejeté l'appel avec 'A valid X-API-Key header is required'. Le correctif consiste à utiliser la même API_KEY que celle du conteneur, à envoyer l'en-tête attendu et à vérifier les logs de l'API et du worker avant de relancer le job.

RELANCE POSSIBLE

Comment éviter que l'utilisateur reste sans explication ?

ÉLÉMENT À MONTRER

Écran de statut, logs et authentification API key.

QUESTION 24

Comment sécuriser un upload de fichier ?

RÉPONSE MODÈLE

Je limite la taille et les extensions, je vérifie le type réel du fichier, je génère un nom interne, je stocke hors du répertoire exécutable et je traite le document dans un worker isolé. J'ajoute une analyse antivirus si le contexte l'exige, je protège contre le path traversal et je ne fais jamais confiance au nom fourni par le navigateur.

RELANCE POSSIBLE

Que faites-vous des fichiers temporaires ?

ÉLÉMENT À MONTRER

Route d'upload, stockage objet et worker.

QUESTION 25

Comment passer à plus de 500 documents ?

RÉPONSE MODÈLE

Je sépare ingestion et requête, j'utilise une file de jobs, je rends l'indexation idempotente et je parallélise avec plusieurs workers si nécessaire. Je surveille la taille des chunks, le débit, les erreurs par document et la capacité de Qdrant. Pour l'entreprise, je prévois une reprise sur erreur, une stratégie de déduplication et un reindexing versionné.

RELANCE POSSIBLE

Quel serait le premier goulot d'étranglement ?

ÉLÉMENT À MONTRER

Redis, worker, Qdrant et métriques de batch.

QUESTION 26

Comment éviter les doublons lors d'un re-upload ?

RÉPONSE MODÈLE

Je calcule une empreinte du contenu, je la stocke avec le document et je l'utilise pour détecter un doublon. Pour une nouvelle version, je conserve un document_id stable, une version et un statut. La suppression ou le remplacement doit retirer les anciens chunks du namespace avant d'ajouter la nouvelle version.

RELANCE POSSIBLE

Comment gérer une indexation partiellement réussie ?

ÉLÉMENT À MONTRER

Job status, document hash et identifiants de chunks.

QUESTION 27

Comment diagnostiquez-vous un document qui ne s'indexe pas ?

RÉPONSE MODÈLE

Je commence par l'ID du job et le statut retourné par l'API. Ensuite je vérifie le log API, le log worker, l'existence de l'objet, l'extraction de texte, les variables d'environnement, la connexion Qdrant et l'authentification. Je reproduis avec un fichier minimal, puis j'ajoute un test de régression avant de corriger.

RELANCE POSSIBLE

Quelle information doit apparaître dans l'interface ?

ÉLÉMENT À MONTRER

Logs Docker et statut d'indexation.

6. Sécurité et préparation production

Une bonne réponse de niveau entreprise distingue le prototype local, la préproduction et les exigences de production.

QUESTION 28

Comment l'API est-elle protégée ?

RÉPONSE MODÈLE

L'API utilise une clé configurée par variable d'environnement et l'interface web demande cette clé lorsque l'authentification est activée. La clé ne doit pas être commitée et doit être remplacée par un secret manager en production. Pour une vraie organisation, je compléterais avec SSO/OIDC, des rôles et une rotation des secrets.

RELANCE POSSIBLE

Pourquoi une API key n'est-elle pas suffisante ?

ÉLÉMENT À MONTRER

AUTH_ENABLED et API_KEY dans .env.example.

QUESTION 29

Quels secrets ne doivent pas aller sur GitHub ?

RÉPONSE MODÈLE

API_KEY, OPENAI_API_KEY, mots de passe PostgreSQL et MinIO, tokens et credentials cloud. Le dépôt ne contient qu'un exemple de configuration avec des valeurs fictives. Les secrets réels sont injectés localement ou via un secret manager et doivent être révoqués s'ils ont été exposés.

RELANCE POSSIBLE

Que faites-vous si un secret a été publié ?

ÉLÉMENT À MONTRER

.gitignore, .env.example et historique Git.

QUESTION 30

Comment configurez-vous CORS ?

RÉPONSE MODÈLE

Je limite CORS aux origines connues de l'interface et des environnements autorisés. En local, l'origine peut être localhost ; en production, elle doit être le domaine HTTPS réel. Je n'utiliserais pas un wildcard avec des credentials, et je testerais les méthodes et headers réellement nécessaires.

RELANCE POSSIBLE

Que change le passage en HTTPS ?

ÉLÉMENT À MONTRER

CORS_ORIGINS et reverse proxy.

QUESTION 31

Quelles protections ajouter avant un déploiement public ?

RÉPONSE MODÈLE

Reverse proxy HTTPS, rate limiting, SSO, rôles et filtrage par tenant, validation stricte des fichiers, scans de dépendances, logs centralisés, sauvegardes chiffrées, rotation de secrets, health checks et alertes. Je documenterais aussi un plan de restauration et un processus d'incident.

RELANCE POSSIBLE

Qu'est-ce qui est déjà local et qu'est-ce qui est à externaliser ?

ÉLÉMENT À MONTRER

Roadmap production du dossier.

QUESTION 32

Comment sauvegarderiez-vous les données ?

RÉPONSE MODÈLE

Je sauvegarderais PostgreSQL, les objets MinIO et les snapshots ou exports du vector store, avec une rétention et un chiffrement. Je testerais régulièrement la restauration, car une sauvegarde jamais restaurée n'est pas une garantie. Les documents et les index doivent avoir des versions compatibles.

RELANCE POSSIBLE

Quel objectif RPO/RTO choisiriez-vous ?

ÉLÉMENT À MONTRER

Services persistants et volumes Docker.

QUESTION 33

Comment surveilleriez-vous le système ?

RÉPONSE MODÈLE

Je suivrais la disponibilité des services, la latence p50/p95, le taux d'erreur, le temps d'indexation, la taille de la file Redis, le nombre de chunks, les échecs d'authentification et la qualité retrieval. J'ajouterais un request_id et des dashboards avec alertes, sans exposer les contenus sensibles dans les logs.

RELANCE POSSIBLE

Quelle alerte est prioritaire ?

ÉLÉMENT À MONTRER

Endpoint health, logs et métriques.

QUESTION 34

Comment passeriez-vous du local au cloud ?

RÉPONSE MODÈLE

Je conserverais l'image applicative mais externaliserais les composants stateful vers des services managés ou des volumes durables. Je définirais une configuration par environnement, un registry, un reverse proxy, un secret manager, des migrations et un pipeline CI/CD. Le changement principal n'est pas seulement Docker : c'est la fiabilité opérationnelle et la gouvernance des données.

RELANCE POSSIBLE

Kubernetes est-il obligatoire ?

ÉLÉMENT À MONTRER

Docker Compose et documentation de déploiement.

7. Tests, métriques et questions difficiles

Ces réponses vous permettent de montrer une démarche d'ingénieur : hypothèse, mesure, test, correction.

QUESTION 35

Quels tests avez-vous ou devriez-vous avoir ?

RÉPONSE MODÈLE

Des tests unitaires couvrent le chunking, la fusion, le reranking et les filtres. Des tests d'intégration vérifient upload, indexation, Qdrant, API key et réponse citée. Des tests end-to-end lancent le parcours navigateur. Enfin, des tests de sécurité couvrent l'accès refusé, le path traversal, les fichiers invalides et l'isolation des tenants.

RELANCE POSSIBLE

Quel test aurait détecté l'erreur API key ?

ÉLÉMENT À MONTRER

Répertoire tests et test de workflow upload.

QUESTION 36

Comment évalueriez-vous un système RAG ?

RÉPONSE MODÈLE

Je constituerais un jeu de questions représentatives avec les passages de référence. Je mesurerais recall ou hit@k du retrieval, précision des citations, faithfulness de la réponse, taux de refus correct, latence et coût. J'ajouterais une évaluation humaine pour la pertinence et je comparerais chaque modification à une baseline.

RELANCE POSSIBLE

Quelle métrique ne suffit pas seule ?

ÉLÉMENT À MONTRER

Section évaluation et limites.

QUESTION 37

Comment prouvez-vous que le projet est de qualité ?

RÉPONSE MODÈLE

Je montre une architecture lisible, un démarrage reproductible, des tests, des logs, des erreurs explicites, des citations et une documentation honnête. Je montre aussi les limites : l'API key locale n'est pas un SSO, le modèle template n'est pas une garantie de qualité LLM et les métriques doivent être mesurées sur des données annotées.

RELANCE POSSIBLE

Quel est le principal risque technique ?

ÉLÉMENT À MONTRER

README, tests, dossier technique et démonstration.

QUESTION 38

Que feriez-vous si les réponses sont bonnes mais lentes ?

RÉPONSE MODÈLE

Je décomposerais la latence par étape : embedding, sparse search, dense search, reranker, génération et réseau. Puis je limiterais le top-k, mettrais en cache les embeddings ou les requêtes sûres, utiliserais un modèle plus léger et paralléliserais les recherches. Je vérifierais le p95 plutôt que de me baser sur un seul exemple.

RELANCE POSSIBLE

Que feriez-vous si la qualité baisse après optimisation ?

ÉLÉMENT À MONTRER

Métriques de latence et de qualité séparées.

QUESTION 39

Quelle limite actuelle présenteriez-vous spontanément ?

RÉPONSE MODÈLE

Je préciserais que l'authentification est adaptée à un environnement local de démonstration mais qu'un déploiement entreprise exige SSO, RBAC, rotation des secrets et audit renforcé. Je signalerais aussi que la qualité dépend du corpus, du modèle et du jeu d'évaluation. Cette transparence est préférable à une promesse non mesurée.

RELANCE POSSIBLE

Quelle amélioration prioriseriez-vous ?

ÉLÉMENT À MONTRER

Roadmap et configuration de sécurité.

QUESTION 40

Que répondez-vous si on vous demande un score que vous n'avez pas ?

RÉPONSE MODÈLE

Je dirais clairement que je ne veux pas inventer un chiffre. Je présenterais la méthode de mesure prévue, la baseline, le jeu de test et les seuils d'acceptation. Puis je proposerais de lancer l'évaluation avec les données de l'entreprise, car la performance réelle dépend du domaine et des questions.

RELANCE POSSIBLE

Comment convaincre sans score ?

ÉLÉMENT À MONTRER

Protocole d'évaluation reproductible.

8. Questions comportementales et posture

Le recruteur cherche ici votre maturité, votre capacité à apprendre et votre sens des compromis.

QUESTION 41

Quelle décision technique a été la plus difficile ?

RÉPONSE MODÈLE

Le choix local-first était un compromis. Il facilite la confidentialité, le coût et la reproductibilité, mais il impose de bien gérer les modèles, les volumes et l'observabilité. J'ai donc séparé les interfaces des services et documenté les points à externaliser pour garder une trajectoire cloud possible.

RELANCE POSSIBLE

Quel compromis feriez-vous différemment ?

ÉLÉMENT À MONTRER

Architecture local-first et roadmap cloud.

QUESTION 42

Parlez d'un problème que vous avez rencontré.

RÉPONSE MODÈLE

L'upload affichait 0/1 indexé parce que l'API exigeait un X-API-Key valide. J'ai relié le message d'interface au log serveur, vérifié la configuration effective dans Docker et corrigé l'envoi de l'en-tête côté web. J'ai ensuite documenté la procédure de lecture de la clé et le diagnostic, afin que le problème soit reproductible et compréhensible.

RELANCE POSSIBLE

Qu'avez-vous appris ?

ÉLÉMENT À MONTRER

Historique du bug et écran de connexion API.

QUESTION 43

Que feriez-vous avec une semaine supplémentaire ?

RÉPONSE MODÈLE

Je prioriserais une suite d'évaluation avec un corpus annoté, le RBAC ou OIDC, le rate limiting, les sauvegardes restaurables et un pipeline CI. Ensuite, j'améliorerais le monitoring et la déduplication des documents. Je choisirais selon le risque métier et non selon la fonctionnalité la plus visible.

RELANCE POSSIBLE

Comment choisiriez-vous la priorité ?

ÉLÉMENT À MONTRER

Roadmap priorisée dans le dossier.

QUESTION 44

Comment expliquez-vous un sujet complexe à un client non technique ?

RÉPONSE MODÈLE

Je commence par le résultat : l'utilisateur pose une question et reçoit une réponse avec les passages qui la justifient. Ensuite seulement, j'explique que le système cherche dans les documents, combine plusieurs méthodes et applique des contrôles. J'évite de présenter le LLM comme une source de vérité et je parle de vérifiabilité.

RELANCE POSSIBLE

Pouvez-vous le dire en une phrase ?

ÉLÉMENT À MONTRER

Pitch 30 secondes ci-dessous.

QUESTION 45

Pourquoi ce projet est-il pertinent pour ce poste ?

RÉPONSE MODÈLE

Il réunit backend, data, NLP, recherche d'information, sécurité et produit. Il montre que je sais passer d'un prototype à une plateforme structurée : définir les interfaces, diagnostiquer un incident, automatiser l'environnement et expliquer les limites. Je peux donc contribuer à la fois à la qualité du modèle et à la fiabilité du service.

RELANCE POSSIBLE

Quelle compétence voulez-vous approfondir ?

ÉLÉMENT À MONTRER

Dépôt GitHub et démonstration locale.

Réponses flash à mémoriser

Utilisez ces formulations lorsque le recruteur vous demande une réponse courte.

Question	Réponse courte
Le projet en une phrase	Une plateforme RAG local-first qui répond à partir de documents cités et route les demandes vers des outils contrôlés.
Pourquoi hybride ?	BM25 capte les termes exacts ; le dense capte le sens ; RRF combine les deux.
Pourquoi des citations ?	Pour rendre la réponse vérifiable et limiter la confiance aveugle dans le modèle.
Pourquoi un worker ?	Pour découpler l'upload de l'indexation et absorber les traitements longs sans bloquer l'API.
Premier risque en production	L'accès aux données : il faut SSO, rôles, isolation tenant, audit et secrets correctement gérés.
Métrique prioritaire	Recall du retrieval et faithfulness de la réponse, avec latence et taux d'erreur en parallèle.
Limite honnête	Les performances doivent être mesurées sur un corpus et des questions représentatifs de l'entreprise.

Questions à poser au recruteur

Terminez l'entretien avec deux ou trois questions qui montrent votre orientation produit et fiabilité :

- Quel est le corpus documentaire prioritaire et comment mesurez-vous aujourd'hui la qualité des réponses ?
- Quelles contraintes de confidentialité, de résidence des données et de SSO dois-je intégrer ?
- Le poste est-il davantage orienté retrieval, plateforme backend, évaluation ou mise en production ?
- Quel serait le premier problème concret que vous aimeriez me voir résoudre ?

CONSEIL FINAL

Pendant la démonstration, posez une question dont la réponse est clairement présente dans un document, montrez les citations, puis provoquez volontairement un cas sans preuve. Cela montre à la fois la valeur et les limites du système.

Référentiel du projet : BilalBouizdouzene/Enterprise-RAG-Agentic-AI-Platform